ni 渠道质量测试报告

Gemini Channel Quality Test Re

测试地址	http://51.81.184.93:32691/
令牌分组	gemini-ssvip / gemini-image / Gemini-T1
测试时间	2026-03-28
测试范围	Gemini 2.0 / 2.5 / 3.1 系列全模型
测试项目	可用性 · 延迟 · 并发 · 流式 · 视觉 · 工具调用 · Embedding · 缓存

评估维度	评分	说明
整体可用性	●●●●○	核心模型全部可用，部分 preview 版本缺失渠道
响应延迟	●●●●○	Flash 系列 ~1.5s，Pro 系列 3~10s（含 thinking）
并发稳定性	●●●●●	20并发零失败，墙钟时间几乎不随并发增加
功能完整性	●●●●●	流式/工具调用/视觉/JSON/Embedding 全部通过
缓存命中率	●●○○○	当前 prompt 较短，未触发隐式缓存（正常）

1 模型可用性测试

对 gemini 分组令牌下所有已知模型进行可用性探测，结果如下：

Gemini 2.x 系列

模型名称	状态	备注	基准延迟
gemini-2.0-flash	可用	主力模型，响应正常	~960ms
gemini-2.0-flash-001	不可用	该分组无此渠道	—
gemini-2.0-flash-exp	不可用	该分组无此渠道	—
gemini-2.0-flash-lite	不可用	该分组无此渠道	—
gemini-2.0-flash-lite-001	不可用	Gemini-T1 分组无渠道	—
gemini-2.0-pro-exp	不可用	该分组无此渠道	—
gemini-2.5-flash	可用	支持 Thinking 推理	~1.2s
gemini-2.5-flash-nothinking	可用	无思考模式，响应快	~1.0s
gemini-2.5-pro	可用	高级推理，含 thinking	2.7s
gemini-2.5-pro-preview-03-25	不可用	该分组无此渠道	—
gemini-flash-latest	可用	别名路由	~1.0s
gemini-pro-latest	可用	别名路由	~1.0s
gemini-flash-lite-latest	可用	Lite 版本	~1.0s
gemini-1.5-pro	不可用	该分组无此渠道	—
gemini-1.5-flash	不可用	该分组无此渠道	—

Gemini 3.1 系列（2026年2月~3月发布）

模型名称	状态	备注	基准延迟
gemini-3.1-pro-preview	可用	高推理能力，延迟波动大	4~141s
gemini-3.1-pro-preview-customtools	可用	工具调用优化版	3~6s
gemini-3.1-pro-preview-high	可用	高 thinking budget	长
gemini-3.1-pro-preview-low	可用	低 thinking budget	4~8s
gemini-3.1-flash-lite-preview	可用	最轻量，高并发首选	~1.4s
gemini-3.1-flash-image-preview	可用	多模态图像理解	~1.7s
gemini-3.1-flash-preview	不可用	该分组无此渠道	—

模型名称	状态	备注	基准延迟
gemini-3.1-flash-live-preview	❌ 不可用	该分组无此渠道（实时语音）	—
gemini-3.1-pro-preview-medium	❌ 不可用	gemini-image 分组无渠道	—

Embedding & 其他

模型名称	状态	备注	基准延迟
gemini-embedding-001	✅ 可用	3072维向量，正常	~1.2s
text-embedding-004	❌ 不可用	该分组无此渠道	—
imagen-3.0-generate-002	✅ 可用	图像生成（列表可见）	未测

2 功能完整性测试

测试项目	结果	详情
非流式对话	▯ 可用	gemini-2.0-flash / 2.5-pro 均正常，finish_reason=stop
流式对话 (SSE)	▯ 可用	SSE 格式正确，chunk 分片正常，首 token 延迟 <1s
多轮对话记忆	▯ 可用	正确记住上下文（用户名 Alice），messages 历史传递正常
Function Calling	▯ 可用	正确触发 get_weather 工具，参数 {"location":"Beijing"} 准确
JSON 输出模式	▯ 可用	response_format: json_object 返回合法 JSON，字段完整
视觉/图像理解	▯ 可用	base64 PNG 输入，正确识别颜色（Red/Blue），image_tokens 正常计费
Embedding	▯ 可用	gemini-embedding-001 返回 3072 维向量，数值正常
Thinking 推理	▯ 可用	gemini-2.5-flash/pro 及 3.1-pro-preview reasoning_tokens 正常计费
3.1-customtools 工具调用	▯ 可用	search_web 工具正确触发，reasoning_tokens=77，响应 3.5s
3.1-flash-lite 流式	▯ 可用	SSE 分片流畅，无 reasoning_tokens（非思考模型），2s 完成
外部 URL 图片	▯ 不可用	403 下载失败（服务端下载 Wikipedia 图片被拒），需用 base64

Token 计费字段说明

字段	说明
`prompt_tokens_details.cached_tokens`	缓存命中的 prompt token 数，当前测试均为 0
`completion_tokens_details.reasoning_tokens`	Thinking 模型的思考 token 数（2.5/3.1 Pro 系列有值）
`prompt_tokens_details.image_tokens`	图片占用的 token 数（100×100 PNG = 272 tokens）
`prompt_tokens_details.text_tokens`	纯文本 prompt token 数

3 延迟性能测试

Gemini 2.x 系列 — 10次连续请求延迟（gemini-2.0-flash）

请求	延迟	请求	延迟
#1	993ms	#6	917ms
#2	921ms	#7	996ms
#3	996ms	#8	1003ms
#4	994ms	#9	1057ms
#5	942ms	#10	891ms

统计项	数值	统计项	数值
最小延迟	891ms	最大延迟	1057ms
平均延迟	~961ms	标准差	~50ms

Gemini 3.1 系列 — 单请求基准延迟（3次采样）

模型	第1次	第2次	第3次	均值	稳定性
gemini-3.1-flash-lite-preview	1350ms	1405ms	1487ms	1414ms	**极稳定**
gemini-3.1-flash-image-preview	2137ms	1548ms	1747ms	1811ms	**稳定**
gemini-3.1-pro-preview-customtools	3590ms	5470ms	3114ms	4058ms	**一般**
gemini-3.1-pro-preview-low	4092ms	5741ms	7684ms	5839ms	**波动**
gemini-3.1-pro-preview	7397ms	141275ms	4290ms	—	**不稳定**

 gemini-3.1-pro-preview 第2次请求耗时 141s，原因为 thinking token 超量消耗，生产环境建议使用流式接口并设置合理的 max_tokens 上限。

4 并发性能测试

所有并发测试均使用 Python ThreadPoolExecutor 同时发起请求，测试消息为 "What is 1+1?"，max_tokens=30。

gemini-2.0-flash — 并发测试（5并发）

5个并发请求总墙钟时间：1103ms，所有请求均成功返回正确答案。

gemini-3.1-flash-lite-preview — 并发测试

并发数	成功率	墙钟时间	avg	min	max	p95
1	100%	1634ms	1633ms	1633ms	1633ms	1633ms
5	100%	1888ms	1554ms	1344ms	1887ms	1637ms
10	100%	1831ms	1394ms	1286ms	1829ms	1432ms
20	100%	1926ms	1526ms	1307ms	1922ms	1749ms

□ 20并发零失败，墙钟时间仅 1.9s，与单请求几乎持平，并发扩展性极佳。

gemini-3.1-flash-image-preview — 并发测试

并发数	成功率	墙钟时间	avg	min	max	p95
1	100%	1802ms	1802ms	1802ms	1802ms	1802ms
5	100%	1861ms	1569ms	1439ms	1860ms	1594ms
10	100%	1788ms	1575ms	1469ms	1785ms	1703ms

□ 10并发全部成功，延迟稳定在 1.5~1.8s，多模态处理能力强。

gemini-3.1-pro-preview-customtools — 并发测试

并发数	成功率	墙钟时间	avg	min	max	p95
1	100%	9802ms	9801ms	9801ms	9801ms	9801ms
3	100%	2888ms	2789ms	2666ms	2888ms	2814ms
5	100%	4183ms	3404ms	2560ms	4182ms	4095ms

□ 单请求偶发 ~10s 高延迟（thinking 时间），并发 3~5 时反而更快（约 3s），说明上游有并发加速效果，零失败。

并发性能综合对比

模型	最大测试并发	成功率	墙钟时间	并发评级
gemini-2.0-flash	5	100%	1103ms	□□□□□
gemini-3.1-flash-lite-preview	20	100%	1926ms	□□□□□

模型	最大测试并发	成功率	墙钟时间	并发评级
gemini-3.1-flash-image-preview	10	100%	1788ms	□□□□□
gemini-3.1-pro-preview-customtools	5	100%	4183ms	□□□□
gemini-3.1-pro-preview	—	—	不稳定	□□

5 缓存命中率测试

对 gemini-2.0-flash 使用相同的大 prompt（约 979 tokens）连续发起 3 次请求，观察 cached_tokens 字段。

请求次序	prompt_tokens	cached_tokens	命中率	响应时间	状态
第1次	979	0	0%	1.3s	**未命中**
第2次	979	0	0%	1.5s	**未命中**
第3次	979	0	0%	1.6s	**未命中**

原因分析

1. Gemini 隐式缓存（Implicit Caching）触发条件：

• gemini-2.0-flash：prompt 需超过 32,768 tokens

• gemini-1.5 系列：prompt 需超过 1,024 tokens（该分组不可用）

2. 本次测试 prompt 仅约 979 tokens，远未达到 gemini-2.0-flash 的缓存阈值

3. 缓存命中率为 0% 属于正常现象，并非渠道问题

4. 若需验证缓存功能，建议构造超过 32K tokens 的超长 system prompt 重复请求

5. 或使用 Gemini 原生 API 的显式缓存（Explicit Context Caching）接口

□ 建议：生产环境中若需利用缓存降低成本，应将固定的 system prompt / 文档内容设计为超过 32K tokens，或采用 Gemini API 显式缓存接口预先创建缓存对象。

6 总结与建议

整体评估

评估维度	评分（5星）	说明
整体可用性	●●●●○	核心模型全部可用；gemini-1.5 系列、部分 3.1 preview 版本缺失渠道
响应延迟	●●●●○	Flash 系列 ~1.4s，Pro 系列 3~10s（含 thinking），偶发超长
并发稳定性	●●●●●	20并发零失败，墙钟时间几乎不随并发增加，表现优秀
功能完整性	●●●●●	流式/工具调用/视觉/JSON/Embedding/Thinking 全部通过
缓存命中率	●●○○○	当前 prompt 较短未触发，属正常；需超 32K tokens 才可触发
Token 计费	●●●●○	字段完整，reasoning_tokens 正确计费，image_tokens 正常

问题清单

编号	优先级	问题描述	建议处理
P1	中	gemini-3.1-pro-preview 延迟极不稳定（4s~141s），thinking token 无上限	流式接口 + 合理 max_tokens
P2	低	gemini-1.5 系列在 gemini-ssvip 分组下不可用	补充 gemini-1.5 渠道或确认是否需要
P3	低	gemini-3.1-flash-preview / live-preview 不可用	补充对应渠道配置
P4	低	外部 URL 图片下载失败（403）	使用 base64 编码传递图片
P5	信息	缓存命中率 0%（prompt 未达阈值，非缺陷）	无需处理，属正常行为

使用建议

使用场景	推荐模型	说明
高吞吐/低成本场景	`gemini-3.1-flash-lite-preview`	~1.4s，20并发零失败，成本最低
多模态图文理解	`gemini-3.1-flash-image-preview`	~1.7s，视觉能力强，并发好
工具调用/Agent	`gemini-3.1-pro-preview-customtools`	3~6s，工具调用优化，推荐流式
复杂推理/分析	`gemini-2.5-pro` / `gemini-3.1-pro-preview`	含 thinking，建议流式+大 max_tokens
向量检索	`gemini-embedding-001`	3072维，延迟~1.2s
快速原型/通用	`gemini-2.0-flash`	~960ms，稳定，功能全面

报告生成时间：2026-03-28 14:03 | 测试执行人：系统自动化测试